

Take-Home-Aufgabe

Willkommen und danke für dein Interesse an der Rolle bei **durchblicker**. Diese Aufgabe gibt dir die Gelegenheit, deine Arbeitsweise an einem realitätsnahen Datenszenario zu zeigen.

Kontext

Bei **durchblicker** fließen Daten aus mehreren Quellen zusammen (CRM-Exporte, Tracking, manuelle CSVs). Diese sind oft uneinheitlich formatiert, enthalten Duplikate und KPIs werden je nach Quelle unterschiedlich berechnet. Deine Aufgabe ist es, aus solchen Rohdaten ein sauberes, dokumentiertes Datenmodell zu bauen.

Wir stellen dir zwei CSV-Dateien bereit: **leads.csv** (eine Zeile pro Lead-Interaktion mit einem Vergleichsrechner) und **conversions.csv** (eine Zeile pro Abschluss, verknüpft mit einem Lead). Sie simulieren einen Lead- und Abschluss-Datensatz.

Datensätze

leads.csv

- lead_id, email, vertical (auto/haushalt/leben), source (google/newsletter/direct), created_at, region

conversions.csv

- conversion_id, lead_id, email, premium (Jahresnettoprämie), signed_date, status (active/cancelled/pending)

Rahmenbedingungen

Du darfst KI-Tools nutzen, so viel du willst. Wir bewerten nicht, ob du sie benutzt, sondern ob du die Ergebnisse verstehst, hinterfragst und begründen kannst. Im Interview besprechen wir deine Lösung und deine Entscheidungen.

Lieber weniger, aber durchdacht, als alles halb. Dokumentiere kurz deine Annahmen und offenen Fragen, das ist explizit Teil der Bewertung.

Aufgaben

Aufgabe 1 – Data Profiling & Datenqualität

Bevor du irgendetwas modellierst: Verschaff dir und uns einen Überblick über die Datenqualität beider Dateien.

Liefere ein kurzes Profiling: Zeilenzahlen, fehlende Werte, Duplikate, verdächtige Werte, Wertebereiche. Formuliere daraus eine Liste konkreter Datenqualitätsprobleme und sag jeweils, wie kritisch du sie einschätzt und wie du damit umgehen würdest.

Aufgabe 2 – Lead-to-Conversion-Modell

Baue ein Modell, das Leads mit ihren Conversions verknüpft, sodass ein Fachbereich sehen kann, welche Leads abgeschlossen haben und welche nicht. Das Ergebnis soll eine Tabelle sein, mit der man tatsächlich arbeiten kann.

Triff eine begründete Entscheidung, wie du mit Conversions umgehst, die zu keinem Lead passen, und mit Leads, die nie abgeschlossen haben.

Aufgabe 3 – KPI- & Kundenebenen-Aggregation

Baue aggregierte Modelle, die Fragen beantworten, die der Fachbereich tatsächlich stellt. Mindestens:

- Pro (vertical, source, Monat): Anzahl Leads, Anzahl Conversions und Conversion Rate.
- Eine Sicht auf Kundenebene (eine Zeile pro Kunde): Anzahl Leads, Anzahl Conversions, Summe der aktiven Prämien und ob der Kunde aktuell einen aktiven Vertrag hält.

Mach deine Definitionen explizit, besonders „was als Conversion zählt“ und „was ein Kunde ist“.

Aufgabe 4 – Architektur & Automatisierung (konzeptionell + etwas Code)

Skizziere, wie du aus diesen einmaligen Skripten eine wartbare, wiederkehrende Pipeline machst. Wir erwarten hier keine lauffähige Infrastruktur, sondern klares Denken plus etwas exemplarischen Code.

Adressiere dabei:

- Layer-Struktur (roh/staging/mart oder ähnlich).
- Wo Datenqualitätsprüfungen ansetzen (z. B. dbt Tests / Dataform Assertions).
- Wie oft das laufen sollte und was bei Fehlern passiert.
- Wie du Nachvollziehbarkeit und Dokumentation sicherstellst.

Zeig für einen der Tests bzw. eine der Assertions konkreten Beispielcode.

Abgabe

- Schick uns deinen Code sowie eine kurze Dokumentation deiner Annahmen und offenen Fragen.
- Sprache und Tools bleiben dir überlassen (SQL, Python, dbt/Dataform ...), wähl, womit du am besten zeigen kannst, was du kannst.
- Im anschließenden Gespräch gehen wir deine Lösung gemeinsam durch.

Wir freuen uns auf deine Lösung. Viel Spaß beim Durchblicken!